

Nome: Marcelo Cauan Rodrigues de Moura

Matrícula: 2023122094

Modelos de Treinamento por Classificação Utilizados:

- DecisionTreeClassifier
- MLPClassifier
- LogisticRegression (Nome dá a entender que é Regressão, porém é Classificação)

DecisionTreeClassifier

	precision	recall	f1-score	support
airplane	0.34	0.35	0.34	1000
automobile	0.28	0.27	0.28	1000
bird	0.21	0.23	0.22	1000
cat	0.19	0.19	0.19	1000
deer	0.22	0.22	0.22	1000
dog	0.22	0.21	0.22	1000
frog	0.29	0.28	0.29	1000
horse	0.27	0.26	0.27	1000
ship	0.39	0.40	0.39	1000
truck	0.28	0.28	0.28	1000
accuracy			0.27	10000
macro avg	0.27	0.27	0.27	10000
weighted avg	0.27	0.27	0.27	10000

MLPClassifier

	precision	recall	f1-score	support
airplane	0.51	0.50	0.51	1000
automobile	0.64	0.48	0.55	1000
bird	0.32	0.38	0.35	1000
cat	0.35	0.25	0.29	1000
deer	0.38	0.41	0.39	1000
dog	0.41	0.33	0.37	1000
frog	0.43	0.63	0.51	1000
horse	0.48	0.56	0.51	1000
ship	0.59	0.58	0.58	1000
truck	0.56	0.47	0.51	1000
accuracy			0.46	10000
macro avg	0.47	0.46	0.46	10000
weighted avg	0.47	0.46	0.46	10000

LogisticRegression

	precision	recall	f1-score	support
airplane	0.46	0.49	0.47	1000
automobile	0.47	0.47	0.47	1000
bird	0.33	0.29	0.31	1000
cat	0.28	0.26	0.27	1000
deer	0.35	0.29	0.32	1000
dog	0.33	0.33	0.33	1000
frog	0.40	0.46	0.43	1000
horse	0.45	0.44	0.45	1000
ship	0.50	0.53	0.51	1000
truck	0.43	0.46	0.45	1000
accuracy			0.40	10000
macro avg	0.40	0.40	0.40	10000
weighted avg	0.40	0.40	0.40	10000

Análise aos 3 Modelos de Aprendizagem

Analisando os resultados obtidos com os três classificadores aplicados ao conjunto de dados CIFAR-10, podemos observar diferenças claras em termos de desempenho, refletidas nas métricas de precisão, recall e F1-score.

O Logistic Regression apresentou uma acurácia geral de 40%, mostrando um desempenho razoável em classes como “ship” e “airplane”, mas apresentando limitações em classes mais complexas ou com maior variabilidade, como “cat” e “bird”. Sua vantagem está na simplicidade e rapidez de treinamento, porém a desvantagem é a incapacidade de capturar padrões complexos e não lineares presentes em imagens, o que reduz seu desempenho global.

O MLPClassifier, por sua vez, alcançou uma acurácia de 46%, superando o Logistic Regression em quase todas as classes, especialmente em “automobile”, “frog” e “ship”. Isso demonstra sua capacidade de lidar melhor com a complexidade das imagens do CIFAR-10, aproveitando a aprendizagem não linear das redes neurais. A principal vantagem do MLP está justamente em capturar relações mais complexas entre os pixels das imagens, mas isso vem ao custo de maior tempo de treinamento e maior necessidade de recursos computacionais.

Já o Decision Tree Classifier apresentou o pior desempenho, com acurácia de apenas 27%, mostrando-se pouco eficiente para um problema de classificação de imagens como o CIFAR-10. Embora árvores de decisão possam ser intuitivas e interpretáveis, elas não conseguem generalizar bem em conjuntos de dados com alta dimensionalidade e variabilidade, sofrendo de overfitting em muitas classes. Sua vantagem está na

interpretabilidade e facilidade de implementação, mas para imagens coloridas complexas, essa limitação se torna significativa.

Em resumo, o MLP se destaca como o melhor classificador entre os três para o CIFAR-10, equilibrando desempenho e capacidade de lidar com complexidade. Logistic Regression oferece uma solução rápida e simples, mas limitada, enquanto Decision Tree, apesar de intuitiva, apresenta resultados insatisfatórios para este tipo de problema.